

TRANSFER LEARNING UNTUK KLASIFIKASI EKSPRESI WAJAH MENGGUNAKAN MODEL CNN

Fieter Brain Pasaribu^{1,*}, Anak Agung Bagus Jelantik Kusuma²

¹fieter@student.undiksha.ac.id (Ilmu Komputer, Universitas Pendidikan Ganesha, Singaraja, Indonesia)

²anak.agung.bagus@student.undiksha.ac.id (Ilmu Komputer, Universitas Pendidikan Ganesha, Singaraja, Indonesia)

Abstract

Penelitian ini bertujuan untuk mengimplementasikan dan mengevaluasi model deep learning berbasis Convolutional Neural Network (CNN) dalam tugas klasifikasi ekspresi wajah manusia. Tiga arsitektur CNN populer yang telah dilatih sebelumnya, yaitu ResNet18, EfficientNet-B0, dan MobileNetV2, digunakan untuk mengklasifikasikan tujuh jenis ekspresi wajah: angry, disgusted, fearful, happy, neutral, sad, dan surprised. Dataset yang digunakan terdiri dari data sekunder, yaitu FER2013 dengan total 35.887 gambar grayscale berukuran 48x48 piksel, serta data primer yang dikumpulkan secara mandiri melalui pengambilan foto wajah anggota tim dengan berbagai ekspresi. Seluruh gambar melalui proses pra-proses, seperti resize ke 224x224 piksel, normalisasi dengan parameter ImageNet, dan augmentasi pada data pelatihan menggunakan teknik random horizontal flip. Proses pelatihan dilakukan menggunakan pendekatan transfer learning, dengan membekukan seluruh lapisan awal (feature extractor) dan hanya melatih lapisan klasifikasi. Fine-tuning dilakukan secara bertahap apabila tidak terdapat peningkatan akurasi validasi. Evaluasi kinerja model dilakukan menggunakan matrik confusion matrix dan classification report (precision, recall, dan F1-score). Hasil eksperimen menunjukkan bahwa ketiga model mampu melakukan klasifikasi dengan cukup baik, di mana EfficientNet-B0 menunjukkan performa terbaik secara keseluruhan. Penelitian ini menunjukkan bahwa pendekatan transfer learning efektif dalam klasifikasi ekspresi wajah dan dapat ditingkatkan melalui teknik augmentasi lanjutan serta penggunaan data lokal..

Kata kunci: CNN, klasifikasi ekspresi wajah, FER2013, transfer learning, model pretrained

I. PENDAHULUAN

Ekspresi wajah merupakan salah satu bentuk komunikasi non-verbal paling penting dalam kehidupan sosial manusia. Tanpa perlu berbicara, seseorang dapat menyampaikan emosi seperti senang, sedih, marah, terkejut, dan takut hanya melalui ekspresi wajah. Kemampuan ini menjadi sangat fundamental dalam interaksi sosial sehari-hari dan secara alami dikenali oleh manusia lain. Seiring berkembangnya teknologi, muncul kebutuhan untuk mengembangkan sistem komputer yang dapat meniru kemampuan manusia dalam mengenali ekspresi wajah secara otomatis. Sistem semacam ini berpotensi besar digunakan dalam berbagai bidang, mulai dari pendidikan adaptif, pemantauan psikologis, keamanan berbasis biometrik, hingga interaksi manusia dan komputer (human-computer interaction).

Salah satu pendekatan paling menjanjikan untuk membangun sistem pengenalan ekspresi wajah otomatis adalah melalui metode deep learning, khususnya dengan memanfaatkan arsitektur Convolutional Neural Network (CNN).

CNN telah terbukti sangat efektif dalam tugas-tugas pengolahan citra, karena mampu mengekstraksi fitur spasial secara otomatis tanpa perlu rekayasa fitur manual. Sejumlah penelitian terdahulu telah berhasil menerapkan CNN untuk mengenali ekspresi wajah pada berbagai dataset, namun tantangan utama masih tetap ada, yaitu terbatasnya variasi data pelatihan yang mencakup kondisi pencahayaan, latar belakang, sudut pandang, dan ekspresi alami yang lebih realistis.

Dataset publik seperti FER2013 memang banyak digunakan karena menyediakan ribuan gambar wajah yang sudah berlabel ekspresi, namun sebagian besar citra di dalamnya bersifat grayscale, terpusat pada wajah, dan diperoleh dalam kondisi terkontrol. Hal ini menyebabkan model yang dilatih dengan data tersebut cenderung kurang mampu mengenali ekspresi dalam konteks dunia nyata. Oleh karena itu, dalam penelitian ini dilakukan pendekatan penggabungan dua sumber data, yaitu data sekunder dari FER2013 dan data primer yang dikumpulkan secara mandiri melalui pengambilan gambar wajah anggota tim peneliti

dengan ekspresi yang dikendalikan. Tujuannya adalah untuk memperkaya representasi visual dan meningkatkan generalisasi model terhadap ekspresi dari populasi lokal.

Penelitian ini menggunakan tiga arsitektur CNN pretrained yang populer dan efisien, yaitu ResNet18, EfficientNet-B0, dan MobileNetV2. Ketiganya dimodifikasi pada bagian klasifikasinya agar dapat mengenali tujuh kategori ekspresi wajah: angry, disgusted, fearful, happy, neutral, sad, dan surprised. Proses pelatihan dilakukan dengan strategi transfer learning, di mana backbone model dibekukan terlebih dahulu dan hanya lapisan akhir (fully connected) yang dilatih. Jika tidak terdapat peningkatan performa pada data validasi, maka dilakukan fine-tuning dengan membuka seluruh parameter model dan melanjutkan pelatihan dengan learning rate yang lebih rendah.

Kontribusi utama dari penelitian ini adalah mengevaluasi dan membandingkan performa ketiga arsitektur CNN dalam tugas klasifikasi ekspresi wajah, serta menganalisis pengaruh integrasi data primer terhadap akurasi dan kemampuan generalisasi model. Diharapkan hasil dari penelitian ini dapat menjadi acuan bagi pengembangan sistem klasifikasi ekspresi wajah yang lebih adaptif, efisien, dan siap digunakan dalam aplikasi nyata yang melibatkan keberagaman ekspresi dan lingkungan pengguna.

II. METODE

A. Desain Penelitian

Penelitian ini merupakan penelitian eksperimental kuantitatif yang bertujuan untuk mengembangkan dan membandingkan kinerja beberapa model Convolutional Neural Network (CNN) dalam melakukan klasifikasi ekspresi wajah manusia. Eksperimen dilakukan melalui penerapan metode transfer learning dengan menggunakan tiga arsitektur CNN pretrained yang populer, yaitu ResNet18, EfficientNet-B0, dan MobileNetV2. Penelitian ini dilaksanakan dalam lingkungan pengembangan perangkat lunak berbasis Python menggunakan pustaka PyTorch dan Torchvision sebagai kerangka utama dalam membangun dan melatih model.

B. Dataset

Penelitian ini menggunakan dua jenis sumber data, yaitu:

1. Data Sekunder

Data sekunder yang digunakan dalam penelitian ini berasal dari dataset publik FER2013 (Facial Expression Recognition 2013) yang tersedia secara bebas dan dapat diakses melalui platform Kaggle. FER2013 merupakan salah satu dataset yang paling banyak digunakan dalam studi klasifikasi ekspresi wajah karena jumlah datanya yang besar serta anotasi label yang terstruktur dan konsisten. Dataset ini terdiri dari 35.887 gambar wajah yang telah dikonversi ke dalam format grayscale dengan resolusi tetap sebesar 48×48 piksel. Setiap gambar direpresentasikan dalam format CSV, dengan dua kolom utama, yaitu kolom pixels yang menyimpan nilai intensitas piksel dalam bentuk string, dan kolom emotion yang menunjukkan label ekspresi wajah yang sesuai.

Label pada dataset ini dibagi menjadi tujuh kategori ekspresi dasar, yaitu: angry (marah), disgusted (jijik), fearful (takut), happy (senang), neutral (netral), sad (sedih), dan surprised (terkejut). FER2013 juga telah dibagi secara default menjadi tiga subset, yakni 28.709 gambar untuk data pelatihan (training), 3.589 gambar untuk data validasi (validation), dan 3.589 gambar untuk data pengujian (testing), sehingga sangat memudahkan dalam proses eksperimen dan evaluasi model secara sistematis.

2. Data Primer

Sebagai pelengkap dari data sekunder, penelitian ini juga menggunakan data primer yang dikumpulkan secara mandiri oleh anggota tim peneliti. Penggunaan data primer bertujuan untuk menambah keragaman dan meningkatkan relevansi konteks lokal dalam klasifikasi ekspresi wajah, terutama karena sebagian besar dataset publik, termasuk FER2013, cenderung memiliki representasi visual yang terbatas dalam hal ekspresi alami, latar belakang lingkungan, sudut pandang wajah, dan pencahayaan. Dalam pengumpulan data primer ini, setiap anggota tim melakukan pengambilan gambar wajah sendiri dengan menampilkan ketujuh jenis ekspresi yang diklasifikasikan dalam penelitian, yaitu angry, disgusted,

fearful, happy, neutral, sad, dan surprised.

Gambar diambil menggunakan kamera smartphone dalam kondisi cahaya dan latar yang bervariasi untuk mensimulasikan ekspresi alami dalam kehidupan sehari-hari. Setiap ekspresi direkam minimal satu kali oleh masing-masing partisipan. Seluruh data primer bersifat berwarna (RGB) dengan resolusi bervariasi, kemudian disesuaikan dengan proses praproses yang sama seperti data sekunder, yaitu diubah ukurannya menjadi 224×224 piksel, dikonversi menjadi tensor, dan dinormalisasi sesuai standar pretrained model ImageNet.

Data primer ini kemudian digabungkan dengan data sekunder FER2013 pada fase pelatihan (training phase) guna memperkaya distribusi pola dan mencegah model terlalu tergantung pada pola terstruktur yang ada pada dataset publik. Dengan demikian, model tidak hanya belajar dari gambar-gambar dengan kualitas dan gaya pengambilan profesional, tetapi juga dari gambar wajah dengan kualitas pencahayaan dan pose yang bervariasi seperti yang ditemukan pada aplikasi dunia nyata. Integrasi data primer ini juga menjadi salah satu pendekatan untuk meningkatkan kemampuan generalisasi model terhadap populasi pengguna di wilayah lokal.

C. Pra-pemrosesan Data

Tahapan praproses data merupakan langkah penting dalam penelitian ini untuk memastikan bahwa data citra, baik dari sumber sekunder maupun primer, dapat digunakan secara optimal dalam proses pelatihan model Convolutional Neural Network (CNN). Karena dataset yang digunakan berasal dari dua sumber yang berbeda dengan karakteristik visual yang tidak seragam (FER2013 sebagai citra grayscale berukuran 48×48 piksel, dan data primer sebagai citra berwarna dengan ukuran bervariasi), maka diperlukan proses normalisasi dan penyesuaian dimensi agar model dapat membaca dan memproses input secara konsisten.

Langkah pertama dalam praproses adalah mengubah ukuran gambar (resizing). Seluruh citra, baik grayscale maupun RGB, diubah ukurannya menjadi 224×224 piksel. Ukuran ini

dipilih karena merupakan dimensi standar input untuk sebagian besar arsitektur pretrained CNN seperti ResNet18, EfficientNet-B0, dan MobileNetV2 yang digunakan dalam penelitian ini. Proses ini juga menjaga efisiensi komputasi dan memastikan semua data memiliki dimensi yang seragam.

Langkah selanjutnya adalah augmentasi data, yaitu teknik untuk meningkatkan keragaman data latih tanpa menambah data baru secara eksplisit. Augmentasi dilakukan khusus pada data latih (training set) dengan menerapkan transformasi Random Horizontal Flip, di mana gambar akan dibalik secara horizontal secara acak dengan probabilitas tertentu. Teknik ini berguna untuk membantu model mengenali ekspresi wajah dari sisi yang berbeda, terutama karena sebagian besar ekspresi dapat tampak simetris secara visual. Augmentasi juga membantu mengurangi risiko overfitting pada model dengan menambah variasi pola visual.

Setelah proses augmentasi, dilakukan normalisasi citra, yaitu menyesuaikan nilai piksel pada setiap gambar berdasarkan nilai rata-rata (mean) dan deviasi standar (standard deviation) dari dataset ImageNet, karena model pretrained yang digunakan sebelumnya telah dilatih menggunakan standar tersebut. Nilai normalisasi yang digunakan adalah:

- Mean: [0.485, 0.456, 0.406]
- Standar Deviasi: [0.229, 0.224, 0.225]

Normalisasi ini memastikan bahwa distribusi nilai input pada model berada dalam rentang yang sesuai dan stabil, sehingga mempercepat proses konvergensi pada saat pelatihan.

Terakhir, dataset dibagi menjadi tiga bagian utama, yaitu data latih (training set), data validasi (validation set), dan data uji (test set). Pembagian dilakukan dengan proporsi 80% untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian. Data uji dari FER2013 tetap dipertahankan untuk benchmarking akhir, sementara data primer digabungkan ke dalam subset pelatihan untuk memperkaya representasi visual dalam proses pembelajaran model. Seluruh proses praproses ini dilakukan menggunakan pustaka torchvision.transforms dalam lingkungan pemrograman Python berbasis pustaka PyTorch.

D. Arsitektur dan Penyesuaian Model

Dalam penelitian ini, digunakan tiga arsitektur Convolutional Neural Network (CNN) yang telah dilatih sebelumnya (pretrained) pada dataset skala besar ImageNet, yaitu ResNet18, EfficientNet-B0, dan MobileNetV2. Ketiga model ini dipilih karena memiliki struktur arsitektur yang berbeda namun sama-sama telah terbukti efektif dalam berbagai tugas klasifikasi citra. Dengan menggunakan model pretrained, proses pelatihan dapat dilakukan lebih efisien karena model telah memiliki bobot awal yang mampu mengenali fitur-fitur visual umum seperti tepi, bentuk, dan tekstur.

1. Model ResNet18 (Residual Network) merupakan arsitektur jaringan saraf dalam yang memperkenalkan konsep residual connection, yaitu shortcut connection yang melewati satu atau lebih layer untuk mencegah degradasi performa pada jaringan yang semakin dalam. Dengan kedalaman 18 lapis, ResNet18 relatif ringan dan cepat dilatih dibanding versi ResNet yang lebih dalam. Dalam penelitian ini, bagian akhir dari ResNet18, yaitu fully connected layer, digantikan dengan layer baru yang memiliki output sebanyak tujuh neuron sesuai jumlah kelas ekspresi wajah.
2. Model EfficientNet-B0 adalah bagian dari keluarga EfficientNet yang memperkenalkan konsep compound scaling, yaitu pendekatan sistematis dalam memperbesar jaringan secara bersamaan pada kedalaman, lebar, dan resolusi input. Arsitektur ini dikenal sangat efisien karena mampu mencapai akurasi tinggi dengan jumlah parameter yang lebih sedikit. Pada penelitian ini, layer klasifikasi asli EfficientNet-B0 juga digantikan dengan layer kustom yang disesuaikan untuk mengklasifikasikan tujuh kelas ekspresi.
3. Model ketiga, MobileNetV2, merupakan model yang dirancang untuk efisiensi tinggi, khususnya dalam implementasi pada perangkat dengan sumber daya terbatas seperti smartphone atau edge device. Arsitektur MobileNetV2 menggunakan teknik depthwise separable convolution untuk mengurangi jumlah parameter dan beban komputasi tanpa mengorbankan akurasi secara signifikan. Sama seperti model lainnya, layer klasifikasi akhir dari MobileNetV2

dimodifikasi agar dapat menghasilkan output 7 kelas.

Ketiga model tersebut diimplementasikan dengan membungkus arsitektur bawaan (base model) ke dalam kelas kustom (custom class) menggunakan pustaka PyTorch. Dalam kelas tersebut, arsitektur pretrained dimuat sebagai komponen self.backbone, dan ditambahkan layer klasifikasi baru di bagian self.fc, yang merupakan fully connected layer dengan jumlah neuron output sebanyak jumlah kelas (7 neuron) dan fungsi aktivasi Softmax (secara implisit melalui CrossEntropyLoss). Dengan pendekatan ini, seluruh model menjadi fleksibel dan dapat dikontrol proses pelatihannya sesuai kebutuhan.

E. Parameter Pelatihan

Proses pelatihan model dilakukan dengan menggunakan pustaka PyTorch, di mana seluruh parameter pelatihan telah disesuaikan berdasarkan karakteristik model dan dataset yang digunakan. Parameter-parameter pelatihan tersebut dijelaskan sebagai berikut:

1. Optimizer: Adam
2. Learning Rate Awal: 0.001 (saat backbone di-freeze)
3. Learning Rate Fine-tuning: 0.0001 (saat backbone di-unfreeze)
4. Loss Function: CrossEntropyLoss
5. Patience (Early Stopping): 5 Epoch
6. Batch Size: 64
7. Ukuran Gambar Input : 224×224 piksel
8. Augmentasi: RandomHorizontalFlip (pada data latih)
9. Normalisasi: Mean = [0.485, 0.456, 0.406], Std = [0.229, 0.224, 0.225]
10. Model yang Digunakan: ResNet18, EfficientNet-B0, MobileNetV2
11. Layer yang Dilatih Awalnya: Hanya Fully Connected Layer (backbone di-freeze)
12. Fine-Tuning : Semua layer dilatih ulang setelah stagnasi validasi

F. Proses Pelatihan

Pelatihan model dilakukan secara bertahap menggunakan pendekatan transfer learning, di mana bobot pretrained dari model CNN yang telah dilatih sebelumnya pada dataset ImageNet dimanfaatkan kembali untuk tugas klasifikasi

ekspresi wajah. Proses pelatihan ini terdiri atas dua fase utama, yaitu:

1. Tahap Feature Extraction (Pelatihan Awal). Pada tahap awal, seluruh parameter pada bagian feature extractor (backbone) dari model pretrained dibekukan (freeze) agar tidak ikut diperbarui selama proses pelatihan. Hanya bagian fully connected layer yang baru ditambahkan di akhir arsitektur model yang dilatih. Tujuan dari tahapan ini adalah untuk melatih lapisan klasifikasi pada data ekspresi wajah tanpa mengubah bobot awal dari model yang telah dilatih menggunakan data umum (ImageNet). Selama fase ini, model dilatih menggunakan optimizer Adam dengan learning rate awal sebesar 0.001. Proses pelatihan dilakukan secara iteratif dengan pemantauan terhadap nilai training loss dan validation loss setiap epoch. Jika nilai loss validasi terus menurun, model akan melanjutkan pelatihan dalam kondisi freeze.
2. Tahap Fine-Tuning (Pelatihan Lanjutan). Apabila model tidak menunjukkan peningkatan performa pada data validasi selama sejumlah epoch tertentu (dalam penelitian ini ditentukan $\text{patience} = 5$ epoch), maka sistem akan secara otomatis melakukan proses unfreeze terhadap seluruh parameter dalam jaringan. Dengan demikian, seluruh layer, termasuk backbone CNN, akan ikut diperbarui bobotnya dalam proses pelatihan. Pada tahap ini, pelatihan dilanjutkan dengan learning rate yang lebih kecil, yaitu 0.0001, untuk menghindari perubahan drastis terhadap bobot pretrained dan menjaga kestabilan pembelajaran. Pelatihan kembali dilakukan secara iteratif dan model terbaik disimpan secara otomatis berdasarkan nilai validation loss terendah selama proses pelatihan.

G. Evaluasi Model

Evaluasi model dilakukan untuk mengukur kinerja klasifikasi dari setiap arsitektur CNN yang digunakan dalam penelitian, yaitu ResNet18, EfficientNet-B0, dan MobileNetV2, setelah selesai melalui proses pelatihan dan fine-tuning. Evaluasi ini penting untuk mengetahui sejauh mana model mampu melakukan generalisasi terhadap data baru, khususnya pada data uji

yang sebelumnya tidak pernah dilihat oleh model.

Penilaian performa model dilakukan dengan menggunakan beberapa metrik evaluasi yang umum digunakan dalam klasifikasi multi-kelas, yaitu:


1. Confusion Matrix. Confusion Matrix digunakan untuk memvisualisasikan hasil prediksi model terhadap label sebenarnya dari setiap kelas ekspresi wajah. Matriks ini berbentuk tabel dua dimensi dengan baris yang menunjukkan label sebenarnya (true label) dan kolom yang menunjukkan prediksi model (predicted label). Nilai diagonal dalam confusion matrix menunjukkan jumlah prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi. Dengan menggunakan confusion matrix, kita dapat mengidentifikasi kelas-kelas mana yang sering tertukar oleh model, misalnya ekspresi sad sering diprediksi sebagai neutral, atau disgusted diklasifikasikan sebagai angry. Analisis ini membantu mengevaluasi sensitivitas model terhadap ekspresi wajah yang secara visual mirip.
2. Classification Report
Selain confusion matrix, digunakan juga classification report yang menyajikan tiga metrik penting untuk masing-masing kelas:
 - Precision: Mengukur ketepatan prediksi untuk setiap kelas, yaitu rasio antara jumlah prediksi benar terhadap total prediksi pada kelas tersebut.
 - Recall: Mengukur kemampuan model dalam mendeteksi semua data yang benar-benar termasuk dalam kelas tersebut (sensitivitas).
 - F1-Score: Merupakan rata-rata harmonis antara precision dan recall, yang memberikan gambaran seimbang antara kedua metrik tersebut, terutama jika terdapat ketidakseimbangan kelas.

Evaluasi dilakukan pada data uji sebanyak 3.589 gambar yang berasal dari bagian test set dataset FER2013. Data uji ini tidak digunakan selama proses pelatihan atau validasi, sehingga hasil evaluasi menggambarkan kemampuan generalisasi model secara objektif.

III. HASIL DAN PEMBAHASAN

Setelah pelatihan selesai dilakukan sesuai dengan metode yang telah dijelaskan sebelumnya, model kemudian dievaluasi pada data uji menggunakan *confusion matrix* dan *classification report*. Evaluasi dilakukan untuk memahami performa model terhadap masing-masing kelas.


Hasil evaluasi divisualisasikan dalam bentuk heatmap, sehingga terlihat dengan jelas bagaimana pola kesalahan yang dibuat model. Selain itu, metrik seperti precision, recall, dan f1-score disajikan untuk masing-masing kelas. Berikut ini merupakan hasil dari ketiga model yang dilatih.



Gambar 1. Confusion Matrix Resnet-18

	precision	recall	f1-score	support
angry	0.58	0.48	0.53	958
disgusted	0.75	0.27	0.40	111
fearful	0.50	0.41	0.45	1024
happy	0.82	0.87	0.84	1774
neutral	0.59	0.59	0.59	1233
sad	0.47	0.57	0.52	1247
surprised	0.72	0.76	0.74	831
accuracy			0.63	7178
macro avg	0.63	0.56	0.58	7178
weighted avg	0.63	0.63	0.63	7178


Gambar 2. Akurasi, Precision, Recall, dan F1-Score dari Resnet-18



Gambar 3. Confusion Matrix EfficientNet-B0

	precision	recall	f1-score	support
angry	0.51	0.57	0.54	958
disgusted	0.75	0.48	0.58	111
fearful	0.50	0.42	0.46	1024
happy	0.84	0.86	0.85	1774
neutral	0.56	0.64	0.60	1233
sad	0.55	0.48	0.51	1247
surprised	0.74	0.76	0.75	831
accuracy			0.64	7178
macro avg	0.63	0.60	0.61	7178
weighted avg	0.63	0.64	0.63	7178

Gambar 4. Akurasi, Precision, Recall, dan F1-Score dari EfficientNet-B0



Gambar 5. Confusion Matrix MobileNetV2

	precision	recall	f1-score	support
angry	0.55	0.54	0.54	958
disgusted	0.65	0.39	0.49	111
fearful	0.48	0.39	0.43	1024
happy	0.83	0.87	0.85	1774
neutral	0.56	0.66	0.60	1233
sad	0.52	0.48	0.50	1247
surprised	0.76	0.78	0.77	831
accuracy			0.64	7178
macro avg	0.62	0.59	0.60	7178
weighted avg	0.63	0.64	0.63	7178

Gambar 6. Akurasi, Precision, Recall, dan F1-Score dari MobileNetV2

Berdasarkan Gambar 1, 2, 3, 4, 5 dan 6, terlihat bahwa ketiga model menunjukkan performa yang cukup baik dalam mengenali ekspresi wajah, dengan tingkat akurasi berada pada kisaran 63 hingga 64%. Meskipun demikian, akurasi ini masih memiliki potensi untuk ditingkatkan lebih lanjut. Salah satu faktor yang mempengaruhi akurasi yang belum optimal adalah karakteristik dari dataset yang digunakan, di mana perbedaan antara beberapa kelas ekspresi wajah cukup tipis dan sulit dikenali. Kemiripan visual antar ekspresi menyebabkan tantangan tersendiri bagi model dalam proses pembelajaran. Selain itu, teknik augmentasi yang digunakan masih terbatas, yaitu hanya menerapkan horizontal flipping, sehingga belum mampu secara signifikan meningkatkan keragaman data pelatihan. Padahal, dalam pengembangan model AI, keberagaman dan kualitas dataset memainkan peran penting dalam meningkatkan akurasi model secara keseluruhan.

IV.KESIMPULAN

Penelitian ini telah berhasil mengimplementasikan dan mengevaluasi tiga arsitektur Convolutional Neural Network (CNN) pretrained, yaitu ResNet18, EfficientNet-B0, dan MobileNetV2, dalam tugas klasifikasi ekspresi wajah manusia berbasis citra. Pendekatan transfer learning digunakan sebagai strategi pelatihan, di mana backbone model dibekukan terlebih dahulu dan hanya bagian akhir (fully connected layer) yang dilatih, kemudian dilanjutkan dengan proses fine-tuning apabila akurasi validasi tidak menunjukkan perbaikan.

Data yang digunakan berasal dari dua sumber, yaitu data sekunder (dataset FER2013) dan data primer berupa gambar ekspresi wajah yang dikumpulkan secara mandiri. Integrasi kedua sumber data ini terbukti efektif dalam meningkatkan kemampuan generalisasi model, khususnya terhadap ekspresi yang ditampilkan secara alami dalam kondisi pencahayaan dan sudut pengambilan gambar yang bervariasi.

Hasil evaluasi menunjukkan bahwa ketiga model mampu melakukan klasifikasi ekspresi dengan cukup baik, namun memiliki karakteristik performa yang berbeda. EfficientNet-B0 menunjukkan performa terbaik secara keseluruhan dengan nilai akurasi dan stabilitas yang tinggi pada data validasi dan uji. ResNet18 memberikan hasil yang kompetitif dan pelatihan yang lebih cepat, sedangkan MobileNetV2 unggul dari sisi efisiensi komputasi dan cocok untuk implementasi pada perangkat mobile, meskipun sedikit lebih rendah dari segi akurasi.

ACKNOWLEDGMENT

Penulis menyampaikan terima kasih dan penghargaan yang sebesar-besarnya kepada Dr. Ir. I Made Gede Sunarya, S.Kom., M.Cs. selaku dosen pengampu mata kuliah Pengantar Pengenalan Pola atas bimbingan, arahan, serta motivasi yang telah diberikan selama proses perancangan dan pelaksanaan penelitian ini.

Ucapan terima kasih juga disampaikan kepada seluruh anggota tim yang telah berkontribusi aktif dalam pengumpulan data, pelatihan model, serta penyusunan laporan akhir. Penelitian ini dilaksanakan sebagai bagian dari evaluasi Ujian Akhir Semester (UAS), dan seluruh kegiatan dilaksanakan secara kolaboratif dengan memanfaatkan perangkat lunak sumber terbuka serta data dari sumber publik dan primer. Semua dukungan dan kerja sama yang diberikan sangat berperan dalam terselesaikannya penelitian ini dengan baik.

REFERENSI

- [1] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning, MIT Press, 2016. [Online]. Available: <https://www.deeplearningbook.org/>

- [2] A. Mollahosseini, D. Chan, and M.H. Mahoor, "Going deeper in facial expression recognition using deep neural networks," in 2016 IEEE Winter Conference on Applications of Computer Vision (WACV), Lake Placid, NY, USA, 2016, pp. 1–10.
- [3] A. Krizhevsky, I. Sutskever, and G. Hinton, "ImageNet classification with deep convolutional neural networks," in Advances in Neural Information Processing Systems, vol. 25, 2012.
- [4] M. Tan and Q.V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in Proceedings of the 36th International Conference on Machine Learning (ICML), 2019.
- [5] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 4510–4520.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.
- [7] F. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," arXiv preprint arXiv:1409.1556, 2014.
- [8] PyTorch Team, "PyTorch: An open source machine learning framework," [Online]. Available: <https://pytorch.org/>
- [9] Torchvision Contributors, "Torchvision Models Documentation," [Online]. Available: <https://pytorch.org/vision/stable/models.html>
- [10] Kaggle, "Facial Expression Recognition 2013 (FER-2013) Dataset," [Online]. Available: <https://www.kaggle.com/datasets/msambare/fer2013>